JAADARI Firas
Ingénieur IA / ML Senior — Systèmes LLM

✉ jaadari.firas99@gmail.com ☎ +33 6 46 52 41 09
Paris, France
LinkedIn : linkedin.com/in/jaadarix
GitHub : github.com/JAADARI

Profil

Ingénieur IA/ML Senior fort de **5 ans d'expérience** dans la conception, le déploiement et l'exploitation de **systèmes LLM en production** — des pipelines RAG aux workflows agentiques, en passant par le fine-tuning et l'optimisation d'inférence. Impact démontré aussi bien en grands groupes (Crédit Agricole, Carrefour, Infor) qu'en startups à forte croissance (Elyadata, DigeHealth), avec une capacité à traduire des problématiques produit ambiguës en objectifs ML mesurables et à arbitrer pragmatiquement (latence vs. coût, qualité vs. débit). Solides bases sur les patterns agentiques, les frameworks d'évaluation et le déploiement orienté SLO. Bon communicant auprès des équipes produit, infra et métier ; accompagne les équipes via **revues de code**, **pair programming** et exigence sur la qualité Python.

Compétences

- **LLM & IA Agentique :** LangChain, LangGraph, LlamaIndex, Tool Calling, MCP, Guardrails
- **RAG & Recherche d'information :** Recherche Hybride, Reranking, Bases Vectorielles, Neo4j, Embeddings
- **Fine-tuning & Entraînement :** PyTorch, Hugging Face, PEFT (LoRA / Adaptateurs), Fine-Tuning, Pipelines d'entraînement
- **Inférence & Serving :** vLLM, SGLang, HF Inference, AWS Bedrock, Azure OpenAI, Quantification, Optimisation KV-Cache
- **Évaluation & Observabilité :** DeepEval, RAGAS, MLflow, KPIs Hallucination / Fidélité / Pertinence / Précision Contextuelle, A/B Testing, Monitoring de Drift et de Coût, Grafana, Prometheus, OpenTelemetry, CloudWatch
- **Cloud & Infrastructure :** AWS (Bedrock, Lambda, SageMaker, EC2, DynamoDB, S3, Secrets Manager), Terraform, Docker
- **Génie Logiciel :** Python, FastAPI, Pydantic, Pytest, Design Patterns, CI/CD, Git, Ruff, UV
- **Leadership & Communication :** Revue de Code, Pair Programming, Mentorat Technique, Agile/Scrum

Expérience Professionnelle

Crédit Agricole — Paris, France
Ingénieur IA Senior — Plateforme LLM — *Déc. 2024 - Aujourd'hui*

- **Socle LLM — Infrastructure LLM de Production en Entreprise** : Architecte et exploitant de la plateforme LLM fondatrice de la banque (couches d'exposition, d'orchestration et de contextualisation), au service de plusieurs applications GenAI internes sous des SLOs stricts en latence, coût et conformité.
  - Conception d'une **passerelle d'inférence** de production (FastAPI dockerisée sur EC2) exposant des endpoints synchrones, en streaming et en batch pour l'inférence, les embeddings, le reranking et les guardrails, avec une API compatible OpenAI pour une intégration transparente.
  - Optimisation des déploiements d'inférence via **batching de requêtes, mise en cache et autoscaling**, en arbitrant latence vs. coût pour respecter les SLAs produit.
  - Développement de **GenLib**, SDK Python et Lambda Layer AWS centralisant l'authentification, le suivi des tokens, la logique de retry et les appels d'inférence pour toutes les applications GenAI internes.
  - Conception d'une **architecture à plugins extensible** basée sur les **Protocols Python** et les patterns **Registry / Factory**, permettant aux users d'injecter logique métier, outils et sources de retrieval dans le pipeline d'orchestration.
  - Développement d'une suite de **fonctions AWS Lambda** pour les opérations GenAI cœur (authentification, inférence batch / stream / sync, monitoring), déployées via Terraform et pipelines CI/CD.
  - Support de l'exécution multi-runtime sur **CLI, API, Lambda et Kafka**.
  - Intégration de **guardrails** pour la validation entrée/sortie, la détection de prompt injection, le filtrage de toxicité, l'anonymisation PII et la conformité, répondant aux exigences de safety et de gouvernance ML.
  - Conception du **cœur orchestrateur d'agents** qui parse des workflows déclaratifs en pipelines multi-étapes, déléguant l'exécution à des APIs internes et activant le **tool calling** et l'extensibilité **MCP** sans modifier la logique cœur.
  - Mise en place d'un **système de mémoire long terme et court terme** pour les agents, permettant la **persistance conversationnelle** entre sessions via des stores DynamoDB, summarization et stratégies de **compaction de contexte**.
  - Gestion de la **fenêtre de contexte** avec **compaction token-aware** automatique, troncature en sliding window et résumés sémantiques pour maximiser l'usage du contexte dans les limites du modèle.

- Conception d'une stratégie de **Contextual Chunking** enrichissant chaque chunk avec son contexte hiérarchique avant embedding et indexation BM25, réduisant le taux d'erreur de retrieval de **62%**.
- Implémentation de plusieurs **stratégies de chunking** (récursif, sémantique, document-aware) et support de plusieurs **architectures RAG** (*Naive, Graph, Fusion, Agentic RAG*) avec recherche hybride et reranking Cohere.
- Mise en place d'une **stack d'observabilité** complète (CloudWatch, Grafana, Prometheus, OpenTelemetry) suivant latence modèle, débit, consommation de tokens, drift et coût avec dashboards temps réel et alerting.
- Construction de **pipelines d'évaluation automatisés** avec **DeepEval** et **RAGAS** mesurant *fidélité, pertinence des réponses, précision contextuelle et taux d'hallucination*, utilisés pour gérer les releases et benchmarker les versions.
- Développement d'un **système de référentiel** sur DynamoDB (ORM PynamoDB) gérant les tables de souscriptions et de ressources, registre central de la plateforme.

Stack technique : Python, AWS, LangChain, FastAPI

Carrefour — Paris, France

Ingénieur IA — LLM & Systèmes Agentiques — *Déc. 2023 - Déc. 2024*

- **Elpy — Système Agentique GenAI pour la Résolution Autonome de Tickets Support** : Pilotage de la conception et de la livraison d'un système LLM agentique end-to-end qui résout de manière autonome les demandes du support client, réduisant fortement le volume de tickets traités par les humains.
  - Réduction de **60% de la création de tickets support** grâce à un agent LLM combinant **classification d'intentions**, **tool calling** et **retrieval contextuel**.
  - Conception d'une **mémoire conversationnelle court terme** avec état de session sur Redis, permettant des flux de résolution multi-tour et la continuité du contexte entre interactions.
  - Implémentation de **RAG Fusion** avec reciprocal rank fusion pour gérer l'ambiguïté des requêtes : génération de plusieurs reformulations et fusion des résultats pour une meilleure précision de retrieval.
  - **Fine-tuning** de modèles OpenAI (GPT-4) sur des datasets métier curés via des **pipelines d'entraînement JSONL** alignés sur la taxonomie d'intentions de production.
  - Gestion d'Azure OpenAI Service pour le déploiement, la mise à l'échelle et l'optimisation des coûts d'inférence des LLMs et modèles d'embeddings en production.
  - Construction de **pipelines d'évaluation** mesurant le taux de résolution, la précision de classification d'intentions, l'hallucination et la satisfaction utilisateur ; utilisés pour gérer la promotion des modèles et les comparer.

Stack technique : Azure OpenAI, Python, LangChain, Redis, FastAPI, Docker, CI/CD.

Elyadata — Tunis, Tunisie

Ingénieur IA / Software — Inférence LLM & RAG — *Févr. 2023 - Déc. 2023*

- **Plateforme GenAI d'Entreprise — Interface en Langage Naturel sur Bases de Données** : Contributeur principal d'une plateforme LLM interne permettant l'interaction en langage naturel avec des bases structurées, avec un fort accent sur l'**optimisation d'inférence**, le multilingue et le retrieval par knowledge graph.
  - Augmentation du débit d'inférence LLM par **3x** grâce à un microservice basé sur **vLLM** exploitant **PagedAttention** pour la gestion mémoire du KV-cache et le **continuous batching** pour la haute concurrence.
  - Benchmarking et évaluation de plus de 10 LLMs Transformers open-source (Llama 2, Mistral, Mixtral, Falcon) sous contraintes hardware fixes, sélection des modèles de production sur un arbitrage qualité / latence / coût.
  - Implémentation de techniques d'**embeddings sparse** (SPLADE, BM25) pour construire des pipelines de **recherche hybride**, réduisant le coût de calcul tout en améliorant le rappel par rapport aux baselines dense-only.
  - Pilotage d'une initiative **Graph RAG** : pipeline end-to-end transformant des documents non structurés en **knowledge graph Neo4j** pour un retrieval contextuel sémantiquement plus riche.
  - Développement d'un processus d'**extraction d'entités hybride** combinant extraction de relations par LLM et modèles **NER (Transformers)** fine-tunés pour une identification précise des entités.
  - Contributions open-source : feature requests sur **vLLM** (prompt lookup decoding) et **SGLang**.
  - Membre actif du **groupe de lecture de papiers de recherche** interne, présentations sur les architectures RAG, les mécanismes d'attention et l'optimisation d'inférence.

Stack technique : Python, FastAPI, vLLM, LangChain, Docker, Helm, Kubernetes, Grafana, Neo4j, Hugging Face Transformers, PyTorch, Git, GitHub.

DigeHealth — Remote

Data Scientist (Freelance) — Analyse acoustique gastro-intestinale par IA — *Juil. 2023 - Févr. 2024*

- Pipeline ML audio end-to-end : prétraitement (spectrogrammes, MFCCs), débruitage, puis détection et segmentation de bruits abdominaux avec **YOLO** et **Faster R-CNN** ; dashboard **Streamlit** pour la visualisation temps réel. *Python, PyTorch, Signal Processing, Scikit-learn.*

Infor — Tunis, Tunisie

Data Scientist — Prédiction de dégradation BDD en multi-tenant SaaS (ERP M3) — *Nov. 2022 - Juil. 2023*

- Modèles de prévision time-series prédisant les incidents réels de dégradation avant impact tenant ; déploiement sur **Amazon SageMaker** avec endpoints temps réel et réentraînement automatisé. Explicabilité via **SHAP / LIME** pour les équipes SRE. *Python, SageMaker, Scikit-learn, XGBoost.*

Omdena — Remote

Junior Machine Learning Engineer — Cartographie open-source pour la réponse humanitaire — *Sept. 2021 - Nov. 2022*

- Entraînement de U-Net et DeepLabV3+ pour la segmentation de bâtiments avec **transfer learning** depuis le projet RAMP ; co-développement de **HOTLib**, librairie open-source de prétraitement et d'inférence géospatiale. *Python, PyTorch, Deep Learning.*

Langues

— **Anglais :** Professionnel courant (C1)

Distinctions et Récompenses

— **AGEOS** : 1re place classification et cartographie de parcelles d'oliviers à partir de séries temporelles multispectrales Sentinel-2
— **UmojaHack 2023** : 1re place — Cryptojacking Detection Challenge (437 participants)
— **AI Night Challenge 2023** : 1er prix — compétition ML « Respirer Mieux » organisée par Mobelite
— **DataQuest Hackathon** : 1re place (80+ participants)
— **Data Drive 2030** : 3e place sur 966 participants à une compétition mondiale de prédiction des résultats d'apprentissage précoce
— **UmojaHack 2023 CO_2 Prediction** : 9e en Afrique, 2e au niveau national (763 participants)

Formation

— **École Nationale des Sciences de l'Informatique (ENSI, accréditée EUR-ACE)** Manouba, Tunisie
Diplôme National d'Ingénieur en Informatique *Sept. 2019 - Sept. 2022*

Cours principaux : Systèmes d'Exploitation, Algorithmique & Structures de Données, Intelligence Artificielle, Machine Learning, Probabilités & Statistiques, Sécurité Réseaux, Systèmes Distribués.

— **Institut Préparatoire aux Études d'Ingénieurs de Tunis (IPEIT)** Nabeul, Tunisie
Classes Préparatoires Technologie et Physique — Classé 44e sur 1200 *Août 2017 - Juil. 2019*

Cours principaux : Statistiques, Algèbre Linéaire, Physique, Algorithmique, Programmation.